

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Ciencias de la Computación



[CC3092] Deep Learning y Sistemas Inteligentes

Proyecto 2

Integrante	Carné
Daniel Chet	231177
Javier Linares	231135
Cristian Túnchez	231159

Enlace al Repositorio (GitHub)

El trabajo de esta semana se encuentra en el notebook trabajado en este [repositorio](#):



Detección de lavado de dinero en secuencias de remesas

1. El problema, en el contexto guatemalteco

Durante 2024 Guatemala recibió 21,510 millones de dólares en remesas familiares, un récord que equivale a cerca del 19% del producto interno bruto, según el Banco de Guatemala. El corredor con Estados Unidos es uno de los más grandes del mundo, y ese volumen lo vuelve atractivo para quien busca mover fondos ilícitos entre millones de envíos legítimos de bajo monto.

El marco que regula esa vigilancia acaba de cambiar. El Decreto 15-2026, Ley Integral para la Prevención y Represión del Lavado de Dinero u Otros Activos y del Financiamiento del Terrorismo, entró en vigor el 17 de septiembre de 2026 y derogó los decretos 67-2001 y 58-2005 que rigieron durante dos décadas. La supervisión sigue a cargo de la Superintendencia de Bancos a través de la Intendencia de Verificación Especial.

Dos rasgos de la nueva ley importan aquí. Mantiene la obligación de registrar toda transacción en efectivo igual o superior a diez mil dólares, con la regla de que varias operaciones que en conjunto superen ese monto se traten como una sola, que es justamente lo que intenta burlar el fraccionamiento. Y adopta un enfoque basado en riesgo, con manual de prevención documentado y auditoría anual de efectividad, bajo multas de quinientos a trescientos mil dólares. Un sistema que asigne riesgo de forma defendible y deje rastro de por qué lo asignó encaja directamente con esa exigencia.

Nota de validación. Las referencias normativas provienen de fuentes públicas y de comunicados del Congreso. Antes de sustentar una decisión de cumplimiento deben contrastarse con el texto oficial y con el reglamento que emita la Intendencia de Verificación Especial.

El problema técnico

Los sistemas de detección basados en reglas fijas producen más del 95% de falsos positivos, cifra que la literatura de cumplimiento reporta de forma consistente (Cardoso y colaboradores, 2022). Un equipo revisa cientos de casos para encontrar uno real, y mientras tanto los esquemas que reparten el dinero con cuidado no rompen ninguna regla individual.

La causa es que una regla mira una transacción aislada, y una transacción aislada dice poco sobre la intención de quien la envía. Lo que delata el lavado es el patrón a lo largo del tiempo, la frecuencia que se dispara, los montos que se acomodan bajo un umbral, los destinos que cambian de golpe. Este proyecto juzga al remitente completo, no a la transacción.

2. Cómo se representó el problema

La fuente de datos

El planteamiento original proponía PaySim como conjunto principal. La primera verificación fue comprobar si admite lo que el diseño necesita, y no lo admite. Sus 6,362,620 transacciones se reparten entre 6,353,307 cuentas emisoras distintas, con un máximo de tres operaciones por cuenta y solo el 0.15% repitiendo. Una

secuencia por remitente tendría longitud uno en el 99.85% de los casos. PaySim sirve para detección transaccional, que es para lo que se diseñó, pero no para modelar secuencias por remitente.

El conjunto que sí lo admite es IBM Transactions for Anti Money Laundering (Altman y colaboradores, 2023). Se usó el archivo *HI-Small_Trans.csv*, con 5,078,345 transacciones de septiembre de 2022, de las cuales 5,177 están etiquetadas como lavado por expertos en cumplimiento.

De transacciones a secuencias

Un remitente no queda definido por su número de cuenta, porque los identificadores se repiten entre bancos. La clave real es el par banco más cuenta, que produce 496,999 remitentes distintos. Tres decisiones dan forma a la representación, y las tres se tomaron midiendo su costo.

Cuántas transacciones exigir. La mitad de los remitentes envía dos operaciones o menos. Un mínimo de cuatro conserva 142,306 remitentes y 2,085 sospechosos, cubre el 88.2% de las transacciones y alcanza la prevalencia más alta entre los umbrales probados. Bajar a tres habría sumado 673 sospechosos a cambio de admitir secuencias sin historia que leer.

Cuánto historial mirar. La mediana de longitud es de 21 transacciones y el percentil 95 llega a 81. La ventana se fijó en 32 transacciones, que conserva el historial completo del 70.5% de los remitentes. Ampliarla a 48 habría agregado trece puntos de cobertura por un 18% más de cómputo. Se conservan las últimas transacciones, porque el comportamiento reciente es el que se revisa al abrir una alerta.

Qué describe cada transacción. Veinte variables por paso, todas calculadas con información anterior a la transacción para que ningún paso contenga su propio futuro. Cubren monto, tiempo desde la operación previa, hora y día, formato de pago, cruce de banco y de moneda, si el destino es nuevo y cuántas veces se le ha enviado antes, cuánto se desvía el monto del promedio histórico del propio remitente, y si cae en la banda previa al umbral de reporte.

Los montos venían en quince monedas. Las tasas de cambio se derivaron del propio archivo, aprovechando que las operaciones que cambian de moneda revelan la tasa implícita, en lugar de recurrir a una tabla externa.

Desbalance y particiones

Quedan 1,947 remitentes sospechosos frente a 140,359 normales, 72 a 1. Con ese desbalance la exactitud deja de informar, porque responder siempre "normal" acierta el 98.6% de las veces.

La partición se hace por remitente y no por transacción, en 70, 15 y 15 por ciento, estratificada por etiqueta. Dos costos conviene declararlos. Recortar la ventana dejó fuera a 138 remitentes cuya evidencia ocurrió antes de sus últimas treinta y dos operaciones, y el conjunto de prueba queda con 292 casos positivos, suficientes para comparar modelos pero con un margen de error de unos tres puntos porcentuales.

3. El sistema y por qué está armado así

Etapas A, aprender qué es normal

Antes de clasificar lo sospechoso, el sistema aprende lo normal. Un autoencoder secuencial con atención se entrena únicamente con remitentes normales, comprime el comportamiento de cada uno en 128 números y reconstruye desde ahí sus transacciones. Como nunca vio lavado, ante una secuencia desconocida fallará al reconstruirla, y la magnitud de ese fallo es la señal de anomalía. Es la familia de métodos que Pang y colaboradores (2021) clasifican como detección por error de reconstrucción.

Dos decisiones merecen explicarse. La atención vive dentro del compresor y no entre compresor y reconstructor, porque en medio permitiría copiar la entrada y el error dejaría de medir nada. Y el error se promedia sobre las transacciones reales, no sobre los treinta y dos espacios posibles, porque de otro modo quien tiene cuatro operaciones parecería más normal solo por tener menos historia.

El umbral, una decisión de negocio

Se evaluaron dos criterios para fijar el punto de corte. Uno maximiza la métrica F2, que pesa cuatro veces más el recall que la precisión. El otro parte de la capacidad real de revisión, si el equipo puede revisar el 1% de los remitentes, el umbral es el percentil 99. En ambos casos se fija sobre validación y se aplica a prueba, de modo que ninguna cifra reportada se calibró con los datos que la miden.

Etapas B, aprender qué es sospechoso

La etapa A dejó un compresor que sabe describir a un remitente. La etapa B le agrega una capa de decisión entrenada con las etiquetas. La pregunta es qué hacer con el compresor durante ese entrenamiento, y es el problema de transferencia que trata la semana 9 del curso.

Se eligió el ajuste parcial con learning rate diferencial. El diagnóstico fue que el conjunto etiquetado es mediano, 1,363 remitentes positivos, y que el desplazamiento de dominio es moderado. Congelar el compresor lo dejaría incapaz de adaptarse, y ajustarlo al mismo ritmo que la capa de decisión provocaría el olvido catastrófico que describe esa semana, porque la capa nueva empieza aleatoria y sus correcciones iniciales son grandes. El learning rate diferencial resuelve esa tensión. La sección de resultados muestra que el diagnóstico del desplazamiento estaba equivocado.

La función de pérdida

Con 72 normales por cada sospechoso, la función de pérdida estándar queda dominada por los casos fáciles de la clase mayoritaria. Se compararon las dos correcciones de la semana 8. La entropía cruzada ponderada multiplica por veinte el costo de fallar en un sospechoso. La pérdida focal reduce además el peso de los ejemplos ya resueltos, que es lo que convenía aquí, donde la dificultad está en los remitentes que se parecen a ambas clases.

En entrenamiento se conservan todos los positivos y veinte negativos por cada uno, pero la evaluación ocurre sobre la proporción natural, porque una precisión medida sobre datos balanceados no tendría relación con la que vería un equipo real.

Cómo se combinan las dos señales

Se ajustó una regresión logística de dos entradas sobre validación. La elección de un modelo lineal es por auditabilidad, con dos coeficientes se puede decir cuánto aportó cada etapa a cada decisión, que es lo que un supervisor pediría.

4. Resultados

El sistema detecta, y la mejora sobre el estado actual es grande

Con un presupuesto de revisión del 1% del volumen, es decir 218 alertas sobre 21,346 remitentes, el sistema encuentra 147 de los 292 casos de lavado del conjunto de prueba, con una precisión del 69%. En su mejor configuración llega al 59% de los casos con una precisión del 74%.

Los sistemas por reglas operan con tasas de falsos positivos del 95 al 99%, entre una y cinco alertas útiles por cada cien revisiones. Aquí dos de cada tres alertas corresponden a un caso real, de modo que el trabajo del equipo pasa de descartar ruido a investigar casos.

La arquitectura de dos etapas no aportó lo que se esperaba

El experimento de ablación entrenó cada configuración con tres semillas distintas.

Configuración	PR-AUC	Casos detectados	Precisión
---------------	--------	------------------	-----------

Etapa A sola, error de reconstrucción	0.040	8%	10%
Clasificador entrenado desde cero	0.696	59%	74%
Codificador congelado	0.404	34%	50%
Ajuste parcial desde la etapa A	0.604	51%	69%
Ajuste parcial más fusión con la etapa A	0.603	51%	68%
Etapa A con learning rate uniforme	0.676	58%	73%

El resultado contradice la hipótesis del diseño. La receta recomendada, que reutiliza el codificador de la etapa A y lo ajusta con un learning rate reducido, pierde nueve puntos de PR-AUC frente a un clasificador que no usa la etapa A, una brecha trece veces mayor que la variación entre semillas. Combinar ambas señales tampoco ayuda.

De dónde vienen esos nueve puntos

La última fila de la tabla permite el diagnóstico, porque parte de los pesos de la etapa A como la receta recomendada pero entrena a ritmo normal como la línea base. Al compartir un ingrediente con cada una, separa sus efectos.

Origen de la pérdida	Puntos de PR-AUC	Proporción
Partir de los pesos de la etapa A	0.020	22%
Entrenar el codificador diez veces más lento	0.072	78%

Casi cuatro quintas partes del daño no vienen de la representación preentrenada sino del ritmo reducido. Con ritmo uniforme, partir de la etapa A cuesta apenas dos puntos.

Eso corrige el diagnóstico inicial. El ritmo reducido se eligió suponiendo un desplazamiento de dominio moderado entre aprender normalidad y clasificar lavado. El desplazamiento resultó severo, porque las dos tareas piden representaciones distintas, y frenar el codificador le impide adaptarse. Ante un desplazamiento severo la recomendación correcta es la contraria, dejar que el clasificador reescriba la representación a su ritmo.

La raíz del problema sigue estando en la etapa A, cuyo error de reconstrucción apenas separa a las dos clases. El dato que mejor lo ilustra es que el remitente más difícil de reconstruir de todo el conjunto de prueba resulta ser normal. Quien mueve fondos ilícitos por un corredor de remesas se esfuerza en no destacar, y lo consigue.

Cuándo sí serviría la transferencia

La teoría dice que reutilizar un modelo preentrenado rinde sobre todo cuando hay pocos ejemplos etiquetados. Para comprobarlo se repitió el experimento con el 10%, el 25% y el 50% de los casos disponibles.

Casos etiquetados	Desde cero	Ritmo reducido	Ritmo uniforme
136	0.602	0.316	0.523
341	0.631	0.461	0.592
682	0.654	0.549	0.632
1,363	0.696	0.604	0.676

La curva invierte la predicción. El perjuicio es máximo cuando hay pocas etiquetas y se reduce cuando hay más, para las dos variantes. Salir de un punto de partida desfavorable cuesta pasos de entrenamiento, y con pocos ejemplos no alcanzan. La separación entre las dos últimas columnas confirma el diagnóstico en todo el recorrido, el ritmo reducido pesa entre tres y cuatro veces más que la inicialización. Sobre la función de pérdida, la comparación confirmó lo previsto. La pérdida focal superó a la entropía ponderada por casi cinco puntos de PR-AUC.

5. Qué activó cada alerta

Un sistema que no puede explicar sus decisiones no se puede usar bajo un régimen que exige documentar la metodología de riesgo. Se revisaron cinco casos del conjunto de prueba.

Un caso donde el sistema acierta la transacción exacta. El remitente *112497_80543A870* hace solo cuatro operaciones, dos reinversiones sobre su propia cuenta, una de 9,414 dólares apenas por debajo del umbral de reporte, y después dos transferencias en el mismo minuto por el mismo monto, una hacia sí mismo y otra hacia una cuenta nueva en otra moneda. La transacción que el sistema señala como principal responsable es exactamente la que los expertos etiquetaron como lavado.

Un caso de estratificación por instrumentos. El remitente *02915_802063150* empieza con una reinversión de 675,862 euros y sigue con cinco operaciones al mismo destino en veinte minutos usando cinco instrumentos distintos, transferencia

electrónica, tarjeta, cablegráfica, efectivo y cheque. Repartir una suma grande entre instrumentos es una forma conocida de estratificación, y el sistema la marca.

Un caso donde ambas etapas coinciden. El remitente *00020_800195070* cierra dos semanas de pagos rutinarios con tres transferencias a destinos nunca usados, de 14,198, 7,780 y 16,205 dólares, con la segunda justo debajo del umbral de reporte.

Un falso positivo que revela el límite del sistema. El remitente *00001_8008CBDE0* empareja cada movimiento en dólares sobre su propia cuenta con otro en dólares australianos hacia una cuenta externa, en el mismo minuto y por el mismo monto, por sumas de ocho, doce y cuatro millones. Es el perfil de una tesorería institucional liquidando operaciones de cambio, no el de un remitente de remesas. El sistema no tiene forma de saberlo, porque no recibe ninguna información sobre quién es el cliente.

Un caso perdido por margen mínimo. El remitente *00211_807F9DE30* obtuvo una probabilidad de 96.42% frente a un umbral de 96.65%. Se perdió por dos milésimas, y lo notable es que el modelo sí había encontrado lo correcto, señaló como sospechosas una reinversión de 15 libras que rompe con dos operaciones previas de cientos de miles, y la transferencia que efectivamente estaba etiquetada. No falló la discriminación sino el presupuesto de revisión. A este nivel de desempeño, la variable que más mueve la detección ya no es el modelo sino la capacidad que se le asigne al equipo.

6. Limitaciones y qué faltaría para producción

Lo que estos resultados no prueban

El conjunto de prueba tiene 292 casos positivos. Cualquier cifra sobre esa clase carga un margen de error de alrededor de tres puntos porcentuales. Las diferencias que el reporte llama significativas lo son porque superan varias veces ese margen, pero las cifras absolutas no deben leerse con más precisión de la que tienen.

Los datos cubren diecisiete días. Ningún ciclo mensual entra en la ventana, ni nómina, ni servicios, ni el patrón estacional de las remesas. Un sistema entrenado sobre diecisiete días no ha visto lo que es normal en un mes.

Los datos son sintéticos. Los patrones de lavado son los que los autores del simulador decidieron incluir, y ninguna cifra de este reporte puede trasladarse a un corredor concreto sin volver a medirla sobre datos propios.

La partición no cierra del todo la filtración. Separar por remitente impide que una secuencia se reparta entre conjuntos, pero no que dos cuentas de la misma red caigan en conjuntos distintos. El desempeño real sobre redes nunca vistas será probablemente menor.

La etapa A alcanzó el tope de épocas, no la parada temprana. Con trescientas épocas la mejora en las diez previas al óptimo ya era del 2.6%, pero el entrenamiento no se detuvo solo. Una corrida anterior con ochenta épocas daba una brecha menor, de seis puntos en lugar de nueve, lo que sugiere que entrenar mejor el autoencoder empeora la transferencia en vez de mejorarla. Son dos puntos de medición, no una relación demostrada.

Qué haría falta para llevarlo a un corredor real

Información del cliente. El falso positivo analizado se explica por la ausencia de contexto. Un sistema en producción necesita saber si el remitente es persona o empresa, su actividad declarada y su perfil transaccional esperado. Esa información existe en los expedientes de conocimiento del cliente y no entró a este modelo.

Gobierno del umbral y vigilancia de la deriva. El punto de corte del 1% corresponde en una institución al comité que asigna la capacidad de revisión, y debe documentarse junto con sus consecuencias sobre detección y carga de trabajo. Además, los patrones de remesas cambian con la estacionalidad y con la reacción de quien busca evadir el control, así que un sistema que no vigile la deriva de sus entradas deja de servir sin avisar.

Trazabilidad y validación humana. El Decreto 15-2026 exige manual de prevención documentado y auditoría anual de efectividad, lo que implica conservar por cada alerta la versión del modelo, el umbral vigente, las entradas y la explicación emitida. Ninguna alerta debe producir por sí sola un reporte a la autoridad.

Sobre el diseño elegido. A la aplicación se exporta el sistema de dos etapas con ritmo reducido, porque es el que el diseño pide y el que permite mostrar ambas señales al analista. Esa decisión cuesta nueve puntos de PR-AUC frente al clasificador desde cero. En un despliegue real convendría cambiarla por la variante de ritmo uniforme, que conserva las dos etapas y recupera siete de esos nueve puntos, o prescindir de la etapa A como punto de partida y usarla solo como señal secundaria de contexto.

7. Referencias

1. Altman, E., Blanuša, J., von Niederhäusern, L., Egressy, B., Anghel, A., y Atasu, K. (2023). *Realistic Synthetic Financial Transactions for Anti-Money Laundering Models*. Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track.
2. Cardoso, M., Saleiro, P., y Bizarro, P. (2022). *LaundroGraph: Self-Supervised Graph Representation Learning for Anti-Money Laundering*. Proceedings of the Third ACM International Conference on AI in Finance (ICAIF '22), pp. 130-138.
3. Pang, G., Shen, C., Cao, L., y van den Hengel, A. (2021). *Deep Learning for Anomaly Detection: A Review*. ACM Computing Surveys, 54(2), artículo 38, pp. 1-38.
4. Lin, T., Goyal, P., Girshick, R., He, K., y Dollár, P. (2017). *Focal Loss for Dense Object Detection*. Proceedings of the IEEE International Conference on Computer Vision, pp. 2980-2988.
5. Loshchilov, I., y Hutter, F. (2019). *Decoupled Weight Decay Regularization*. International Conference on Learning Representations.
6. Congreso de la República de Guatemala (2026). *Decreto 15-2026, Ley Integral para la Prevención y Represión del Lavado de Dinero u Otros Activos y del Financiamiento del Terrorismo*. Diario de Centro América, 17 de junio de 2026.
7. Banco de Guatemala (2025). *Ingreso de divisas por remesas familiares, cifras de cierre 2024*.

8. Uso de herramientas de IA generativa

Se usó Claude como asistente de programación durante todo el proyecto. Escribió la mayor parte del código de los módulos, de los cuadernos y de la aplicación, redactó los borradores de este reporte, y verificó las referencias normativas y bibliográficas contra sus fuentes.

Las decisiones fueron humanas y en varios casos corrigieron al asistente. Entre ellas, mantener Kaggle como fuente citable en lugar del espejo público que el asistente prefería por comodidad, elegir el número de cuadernos y el destino del despliegue, y autorizar el experimento de escasez de etiquetas.

Dos correcciones merecen mención. La primera fue notar que la etapa A no había convergido, lo que llevó a cuadruplicar su presupuesto de entrenamiento. La segunda fue exigir que se separara el efecto de la inicialización del efecto del learning rate, lo que produjo la configuración que sostiene el diagnóstico central de este reporte. Sin esa exigencia la conclusión habría quedado confundida entre dos causas.

La ejecución se hizo en Colab con GPU, y los resultados reportados son los de esa corrida.