

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Ciencias de la Computación



[CC3092] Deep Learning y Sistemas Inteligentes

Proyecto 2

Integrante	Carné
Cristian Túnchez	231359
Daniel Chet	231177
Javier Linares	231135

DETECCIÓN DE LAVADO DE DINERO EN SECUENCIAS DE REMESAS

El Problema (en el contexto guatemalteco)

Durante 2024, Guatemala recibió USD 21,510 millones en remesas familiares, equivalentes a cerca del 19% del producto interno bruto, según el Banco de Guatemala. El corredor de remesas con Estados Unidos se encuentra entre los más grandes del mundo, por lo que su volumen puede ser aprovechado para mover fondos ilícitos entre millones de envíos legítimos de bajo monto.

El marco regulatorio para la prevención y detección de estas operaciones cambió con la entrada en vigor, el 17 de septiembre de 2026, del Decreto 15-2026, Ley Integral para la Prevención y Represión del Lavado de Dinero u Otros Activos y del Financiamiento del

Terrorismo. Esta ley derogó los decretos 67-2001 y 58-2005, vigentes durante las dos décadas anteriores. La supervisión continúa a cargo de la Superintendencia de Bancos, mediante la Intendencia de Verificación Especial.

La nueva ley mantiene la obligación de registrar las transacciones en efectivo iguales o superiores a USD 10,000. También establece que varias operaciones que, en conjunto, superen ese monto deben tratarse como una sola transacción. Esta disposición busca detectar el fraccionamiento, práctica que consiste en dividir una operación de mayor monto en varias operaciones pequeñas para evitar los controles establecidos.

Además, la ley adopta un enfoque basado en riesgo, mediante el cual las operaciones se evalúan según la probabilidad y el impacto de que representen una actividad ilícita. Las entidades deben contar con un manual de prevención documentado y realizar una auditoría anual de su efectividad, con multas de entre USD 500 y USD 300,000.

En este contexto, un sistema que asigne un nivel de riesgo de forma justificable y conserve evidencia de los factores que determinaron cada asignación permite respaldar el cumplimiento de estas exigencias.

El Problema Técnico

Los sistemas de detección basados en reglas fijas pueden generar más del 95% de falsos positivos, según reporta de forma consistente la literatura sobre cumplimiento normativo (Cardoso et al., 2022). Esto obliga a los equipos de revisión a analizar cientos de casos para identificar una operación realmente sospechosa. Al mismo tiempo, los esquemas de lavado que distribuyen cuidadosamente los fondos pueden evitar que cada transacción individual incumpla una regla.

El problema radica en que las reglas suelen evaluar las transacciones de forma aislada, aunque una operación individual proporciona poca información sobre la intención de quien la realiza. Los indicios de lavado pueden aparecer en el comportamiento acumulado a lo largo del tiempo: aumentos inusuales en la frecuencia, montos ajustados deliberadamente por debajo de determinados umbrales o cambios repentinos en los destinos de las remesas.

Por ello, el sistema analiza el comportamiento del remitente a lo largo del tiempo, en lugar de evaluar únicamente cada transacción de forma independiente.

Cómo se Representó el Problema

La Fuente de Datos

El planteamiento original proponía utilizar *PaySim* como conjunto de datos principal. Sin embargo, al evaluar si permitía construir secuencias por remitente, se encontró una limitación importante. Sus 6,362,620 transacciones corresponden a 6,353,307 cuentas emisoras distintas, con un máximo de tres operaciones por cuenta y solo el 0.15% de las cuentas con transacciones repetidas. Por lo tanto, el 99.85% de las secuencias tendría longitud uno.

PaySim resulta adecuado para la detección transaccional, que es el propósito para el que fue diseñado, pero no para modelar el comportamiento de los remitentes a lo largo del tiempo.

Para este propósito se utilizó el conjunto de datos *IBM Transactions for Anti-Money Laundering* (Altman et al., 2023), específicamente el archivo `HI-Small_Trans.csv`.

Este contiene 5,078,345 transacciones correspondientes a septiembre de 2022, de las cuales 5,177 fueron etiquetadas como operaciones de lavado de dinero por especialistas en cumplimiento.

De Transacciones a Secuencias

El número de cuenta no permite identificar por sí solo a un remitente, ya que los identificadores pueden repetirse entre distintos bancos. Por ello, se utilizó como identificador la combinación de banco y cuenta, lo que permitió distinguir 496,999 remitentes.

La representación de las secuencias se definió a partir de tres decisiones principales: la cantidad mínima de transacciones requerida, la longitud máxima del historial y las variables utilizadas para describir cada transacción.

Cantidad mínima de transacciones

La mitad de los remitentes realiza dos operaciones o menos. Se estableció un mínimo de cuatro transacciones, lo que conserva 142,306 remitentes, incluidos 2,085 sospechosos. Esta selección mantiene el 88.2% de las transacciones y produce la mayor proporción de casos sospechosos entre los umbrales evaluados.

Reducir el mínimo a tres transacciones habría incorporado 673 remitentes sospechosos adicionales, pero también habría permitido secuencias con un historial limitado para identificar patrones de comportamiento.

Longitud del historial

La longitud mediana de las secuencias es de 21 transacciones, mientras que el percentil 95 alcanza 81. Se estableció una ventana máxima de 32 transacciones, con la que se conserva el historial completo del 70.5% de los remitentes.

Ampliar la ventana a 48 transacciones habría aumentado la cobertura en aproximadamente 13 puntos porcentuales, pero también habría incrementado el costo computacional en un 18%. Por ello, se conservaron las transacciones más recientes, ya que estas representan el comportamiento disponible al momento de revisar una alerta.

Variables de cada transacción

Cada transacción se representa mediante 20 variables calculadas únicamente con información disponible antes de dicha operación. Esto evita que una transacción incorpore información de su propio futuro durante el entrenamiento.

Las variables describen el monto, el tiempo transcurrido desde la operación anterior, la hora y el día, el formato de pago, los cambios de banco y moneda, la incorporación de nuevos destinos y la frecuencia con que el remitente les ha enviado dinero. También incluyen la desviación del monto respecto al promedio histórico del remitente y la posición de la operación respecto a la banda previa al umbral de reporte.

Los montos originales estaban expresados en 15 monedas. Las tasas de cambio se calcularon a partir del propio conjunto de datos, aprovechando las operaciones que implican un cambio de moneda para obtener la tasa de cambio implícita. De esta forma, no fue necesario utilizar una fuente externa de tasas.

Desbalance y Particiones

Después del filtrado, quedaron 1,947 remitentes sospechosos frente a 140,359 remitentes normales, una proporción aproximada de 72 a 1. Debido a este desbalance, la exactitud deja de ser una métrica representativa: un modelo que clasificara todos los casos como normales alcanzaría una exactitud del 98.6% sin detectar ningún caso sospechoso.

La partición de los datos se realizó por remitente y no por transacción, con una distribución de 70%, 15% y 15% para entrenamiento, validación y prueba, respectivamente. Además, se mantuvo la proporción de casos sospechosos mediante una partición estratificada.

La reducción de la ventana de historial tuvo como consecuencia que 138 remitentes quedaran fuera porque la evidencia relevante se encontraba antes de sus últimas 32 operaciones. El conjunto de prueba contiene 292 casos positivos, una cantidad suficiente para comparar los modelos, aunque las métricas obtenidas presentan un margen de error aproximado de tres puntos porcentuales.

Arquitectura del Sistema y Justificación de Decisiones

Etapas A: Aprender Qué es Normal

Antes de identificar comportamientos sospechosos, el sistema aprende cómo se comportan los remitentes normales. Para ello, se entrena un **autoencoder secuencial con atención** únicamente con remitentes sin casos de lavado identificados. El modelo

comprime el comportamiento de cada remitente en una representación de 128 valores y, a partir de ella, reconstruye sus transacciones.

Como el modelo no ha sido expuesto a secuencias de lavado durante el entrenamiento, tendrá mayores dificultades para reconstruir comportamientos diferentes a los aprendidos. La magnitud de este error de reconstrucción se utiliza como señal de anomalía. Este enfoque corresponde a la familia de métodos de detección mediante error de reconstrucción descrita por Pang et al. (2021).

Se tomaron dos decisiones relevantes en esta etapa. Primero, el mecanismo de atención se incorpora dentro del compresor y no entre el compresor y el reconstructor. Colocarlo entre ambos permitiría al modelo copiar directamente la información de entrada, reduciendo el valor del error como medida de anomalía.

Segundo, el error se calcula únicamente sobre las transacciones reales de cada secuencia y no sobre los 32 espacios máximos disponibles. De lo contrario, los remitentes con pocas transacciones podrían obtener artificialmente errores menores simplemente por tener un historial más corto.

El Umbral: Convertir una Anomalía en una Alerta

La señal de anomalía debe convertirse en una decisión: determinar a partir de qué nivel un remitente debe considerarse sospechoso. Para establecer este punto de corte se evaluaron dos criterios.

El primero maximiza la métrica **F2**, que otorga cuatro veces más importancia al **recall** (la proporción de casos sospechosos que el sistema logra detectar) que a la precisión. El segundo parte de una restricción operativa: si el equipo de revisión puede analizar como

máximo al 1% de los remitentes, el umbral se establece en el percentil 99 de la puntuación de anomalía.

En ambos casos, el umbral se determina utilizando únicamente el conjunto de validación y posteriormente se aplica al conjunto de prueba. Así se evita ajustar el punto de corte utilizando los mismos datos empleados para medir el desempeño final.

Etapas B: Aprender Qué es Sospechoso

La etapa A produce una representación que resume el comportamiento de cada remitente. La etapa B incorpora una capa de decisión que utiliza esa representación junto con las etiquetas disponibles para aprender qué patrones corresponden a casos sospechosos.

La principal decisión en esta etapa consiste en determinar cuánto debe modificarse el modelo aprendido en la etapa A. Este problema corresponde al **aprendizaje por transferencia**, en el que un modelo previamente entrenado se adapta a una nueva tarea. Se evaluaron distintas estrategias y se seleccionó el ajuste parcial con una tasa de aprendizaje diferencial, es decir, utilizando una tasa menor para las capas previamente entrenadas y una mayor para la nueva capa de decisión.

La selección inicial se basó en que el conjunto etiquetado contenía 1,363 remitentes positivos y presentaba un desplazamiento de dominio moderado. Congelar completamente el compresor impediría que la representación se adaptara a la nueva tarea. Por otro lado, actualizar todas las capas al mismo ritmo podría producir olvido catastrófico, fenómeno en el que el modelo pierde parte del conocimiento adquirido

previamente al adaptarse a datos nuevos. La tasa de aprendizaje diferencial busca reducir este conflicto.

Los resultados muestran, sin embargo, que el diagnóstico inicial sobre el desplazamiento de dominio no fue correcto.

La Función de Pérdida: Dar Mayor Peso a los Casos Difíciles

La proporción de 72 remitentes normales por cada remitente sospechoso provoca un fuerte desbalance entre clases. Con una función de pérdida estándar, los errores sobre la clase mayoritaria pueden dominar el entrenamiento. Por ello, se compararon dos estrategias estudiadas en la semana 8.

La primera es la **entropía cruzada ponderada**, que aumenta el costo de clasificar incorrectamente a los remitentes sospechosos. En este caso, el costo asignado a estos errores es 20 veces mayor. La segunda es la **pérdida focal**, que además reduce progresivamente el peso de los ejemplos que el modelo ya clasifica correctamente. Esto permite concentrar el aprendizaje en los casos más difíciles, particularmente en los remitentes cuyo comportamiento presenta características similares entre ambas clases.

Durante el entrenamiento se conservaron todos los casos positivos y veinte casos negativos por cada positivo. Sin embargo, la evaluación se realizó utilizando la proporción natural de las clases. De esta manera, las métricas reflejan las condiciones que encontraría un equipo de revisión en un escenario real y no las de un conjunto artificialmente balanceado.

Integración de las Señales

Las dos etapas producen señales diferentes sobre el comportamiento de cada remitente: la primera mide cuánto se aleja de los patrones normales y la segunda estima qué tan sospechoso es según los casos etiquetados.

Para combinarlas, se ajustó una **regresión logística** con ambas señales como entradas. Se eligió un modelo lineal por razones de auditabilidad: sus dos coeficientes permiten cuantificar cuánto contribuye cada etapa a la decisión final. Esto facilita explicar a un supervisor por qué un remitente recibió una determinada clasificación.

Resultados

El Sistema Mejora la Detección Bajo una Capacidad de Revisión Limitada

Con un presupuesto de revisión equivalente al 1% del volumen, es decir, 218 alertas entre 21,346 remitentes, el sistema identifica 147 de los 292 casos de lavado presentes en el conjunto de prueba, con una precisión del 69%. En su configuración de mayor precisión, identifica el 59% de los casos con una precisión del 74%.

Los sistemas basados en reglas presentan tasas de falsos positivos de entre 95% y 99%, lo que equivale a encontrar entre uno y cinco casos útiles por cada cien alertas revisadas. En este sistema, aproximadamente dos de cada tres alertas corresponden a un caso real. Esto cambia el tipo de trabajo realizado por el equipo de revisión: en lugar de dedicar la mayor parte del esfuerzo a descartar alertas irrelevantes, puede concentrarlo en investigar casos potencialmente sospechosos.

La Arquitectura de Dos Etapas No Produjo la Mejora Esperada

Se realizó un experimento de ablación, en el que se compararon distintas configuraciones del sistema para determinar qué componentes contribuyen realmente al desempeño. Cada configuración se entrenó con tres semillas aleatorias.

Configuración	PR-AUC	Casos Detectados	Precisión
Etapas A y B, error de reconstrucción	0.040	8%	10%
Clasificador entrenado desde cero	0.696	59%	74%
Codificador congelado	0.404	34%	50%
Ajuste parcial desde la etapa A	0.604	51%	69%
Ajuste parcial + fusión con la etapa A	0.603	51%	68%
Etapas A y B con <i>learning rate</i> uniforme	0.676	58%	73%

Los resultados contradicen la hipótesis inicial del diseño. La configuración recomendada, que reutiliza el codificador de la etapa A y lo ajusta con una tasa de aprendizaje reducida, obtiene una PR-AUC 0.092 menor que el clasificador entrenado desde cero. Esta diferencia es aproximadamente 13 veces mayor que la variación observada entre las semillas.

La combinación de las señales de ambas etapas tampoco mejora el desempeño. Esto indica que la representación aprendida en la etapa A no aporta información adicional suficiente para mejorar la clasificación supervisada.

El Principal Costo Proviene de Reducir la Tasa de Aprendizaje

La última configuración de la tabla permite separar los efectos de la inicialización y de la tasa de aprendizaje. Parte de los mismos pesos utilizados por la configuración recomendada, pero permite que el codificador se actualice a la misma velocidad que el resto del modelo.

Origen de la pérdida	Puntos de PR-AUC	Proporción
Partir de los pesos de la etapa A	0.020	22%
Entrenar el codificador diez veces más lento	0.072	78%

Casi cuatro quintas partes de la pérdida de desempeño se explican por la reducción de la tasa de aprendizaje y no por la inicialización con los pesos de la etapa A. Cuando el codificador se entrena a una tasa uniforme, partir de la etapa A representa una pérdida de apenas 0.020 puntos de PR-AUC.

Este resultado modifica el diagnóstico inicial sobre el desplazamiento de dominio. La estrategia de aprendizaje diferencial se seleccionó bajo la suposición de que existía un desplazamiento moderado entre las tareas de aprender el comportamiento normal y clasificar operaciones de lavado. Los resultados indican que el desplazamiento es severo: ambas tareas requieren representaciones diferentes y, por tanto, el codificador necesita mayor libertad para adaptarse a la tarea supervisada.

El problema de fondo se encuentra en la capacidad de la etapa A para distinguir ambas clases. Su error de reconstrucción presenta poca separación entre remitentes normales

y sospechosos. Una evidencia representativa es que el remitente con mayor error de reconstrucción de todo el conjunto de prueba pertenece a la clase normal. Esto muestra que un comportamiento difícil de reconstruir no implica necesariamente un comportamiento sospechoso.

La Transferencia Tampoco Resulta Favorable con Pocos Datos Etiquetados

La transferencia de aprendizaje suele resultar útil cuando existen pocos ejemplos etiquetados, ya que permite aprovechar representaciones aprendidas previamente. Para comprobar si este supuesto se cumplía en este problema, se repitió el experimento utilizando el 10%, 25% y 50% de los casos etiquetados disponibles.

Casos Etiquetados	Desde Cero	Tasa Reducida	Tasa Uniforme
136	0.602	0.316	0.523
341	0.631	0.461	0.595
682	0.654	0.549	0.632
1,363	0.696	0.604	0.676

Los resultados contradicen la expectativa inicial. La desventaja de utilizar la representación pre-entrenada es mayor cuando hay menos casos etiquetados y disminuye conforme aumenta su disponibilidad. Esto sugiere que, en este problema, la representación inicial no proporciona una ventaja suficiente para compensar el costo de adaptarla con pocos datos.

La diferencia entre las configuraciones con tasa de aprendizaje reducida y uniforme confirma este comportamiento en todo el rango evaluado: el efecto de la tasa de aprendizaje es entre tres y cuatro veces mayor que el efecto de la inicialización.

En cuanto a la función de pérdida, la comparación confirmó la utilidad de priorizar los casos difíciles. La pérdida focal superó a la entropía cruzada ponderada por casi cinco puntos de PR-AUC.

Interpretación de las Alertas: Qué Patrones Detectó el Sistema

La utilidad de un sistema de detección no depende únicamente de su capacidad para identificar casos sospechosos, sino también de la posibilidad de explicar sus decisiones. Esta trazabilidad permite documentar los criterios de riesgo y justificar las alertas generadas. Para evaluar este aspecto, se analizaron cinco casos del conjunto de prueba.

Detección de una Transacción Etiquetada como Lavado

El remitente 112497_80543A870 realiza cuatro operaciones: dos reinversiones en su propia cuenta, una de ellas por USD 9,414, apenas por debajo del umbral de reporte, seguidas de dos transferencias por el mismo monto y en el mismo minuto. Estas últimas se dirigen a una cuenta propia y a una cuenta nueva en otra moneda.

El sistema identifica como principal responsable de la alerta la misma transacción que los especialistas etiquetaron como lavado. En este caso, la detección coincide con la evidencia utilizada para establecer la etiqueta.

Detección de una Posible Estratificación Mediante Distintos Instrumentos

El remitente 02915_802063150 inicia su secuencia con una reinversión de EUR 675,862 y continúa con cinco operaciones hacia el mismo destino en un período de veinte minutos. Cada operación utiliza un instrumento de pago distinto: transferencia electrónica, tarjeta, cablegráfica, efectivo y cheque.

La distribución de una suma elevada entre distintos instrumentos constituye un patrón compatible con la estratificación, una práctica que busca dificultar el seguimiento del origen y movimiento de los fondos. El sistema identifica este comportamiento como sospechoso.

Coincidencia Entre las Dos Etapas

El remitente 00020_800195070 mantiene dos semanas de pagos rutinarios antes de realizar tres transferencias hacia destinos que no había utilizado anteriormente. Los montos son de USD 14,198, USD 7,780 y USD 16,205. La segunda operación queda justo por debajo del umbral de reporte.

La combinación de destinos nuevos, cambios en el comportamiento habitual y un monto cercano al umbral proporciona señales de riesgo que ambas etapas identifican.

Un Falso Positivo Que Evidencia una Limitación de Contexto

El remitente 00001_8008CBDE0 realiza movimientos emparejados: cada operación en dólares hacia su propia cuenta tiene una contraparte en dólares australianos dirigida a una cuenta externa. Las operaciones ocurren en el mismo minuto y por el mismo monto, con sumas de ocho, doce y cuatro millones.

Este patrón es compatible con actividades de tesorería institucional y liquidación de operaciones de cambio, en lugar de remesas personales. Sin embargo, el sistema lo clasifica como sospechoso porque no dispone de información sobre la identidad, el perfil o la actividad económica del cliente.

El caso evidencia una limitación de los datos utilizados: los patrones transaccionales, por sí solos, no siempre permiten distinguir entre una operación legítima de gran escala y una actividad ilícita.

Un Caso Perdido por un Margen Mínimo

El remitente 00211_807F9DE30 obtiene una probabilidad de 96.42%, ligeramente inferior al umbral de 96.65%. Por esta diferencia, el sistema no genera una alerta para el caso.

Sin embargo, el modelo sí identifica las operaciones relevantes: una reinversión de GBP 15 que contrasta con dos operaciones previas de cientos de miles y la transferencia que finalmente fue etiquetada como lavado. El caso muestra que la información necesaria para detectar el comportamiento estaba presente, pero la puntuación no alcanzó el punto de corte establecido.

Por tanto, la omisión no se debe únicamente a la capacidad de discriminación del modelo, sino también a la restricción de revisión. Cuando el sistema opera cerca de su límite de desempeño, la capacidad asignada al equipo y el umbral de alerta adquieren un papel determinante en la cantidad de casos detectados.

Limitaciones y Condiciones para una Implementación Real

Alcance de los Resultados

Los resultados deben interpretarse considerando las limitaciones del conjunto de datos, el diseño experimental y la representación utilizada.

1. **Tamaño del conjunto de prueba.** El conjunto contiene 292 casos positivos. Por ello, las métricas asociadas a esta clase tienen un margen de error aproximado de tres puntos porcentuales. Las diferencias entre configuraciones pueden considerarse relevantes cuando superan ampliamente este margen, pero las cifras absolutas no deben interpretarse con una precisión mayor a la que permite el tamaño de la muestra.
2. **Cobertura temporal limitada.** Los datos abarcan únicamente diecisiete días. Por tanto, no incluyen ciclos mensuales completos, períodos de nómina, pagos de servicios ni posibles patrones estacionales de las remesas. Un sistema entrenado con este período no ha observado suficiente información para caracterizar el comportamiento normal durante un mes completo.
3. **Naturaleza sintética de los datos.** Los datos fueron generados mediante un simulador, por lo que los patrones de lavado presentes dependen de los escenarios definidos por sus autores. En consecuencia, los resultados obtenidos no pueden extrapolarse directamente a un corredor de remesas específico sin validarlos nuevamente utilizando datos propios.
4. **Posible filtración entre redes relacionadas.** La partición por remitente evita que las transacciones de un mismo remitente aparezcan en diferentes conjuntos. Sin embargo, no impide que cuentas pertenecientes a una misma red de actores

aparezcan en conjuntos distintos. Por ello, el desempeño sobre redes de remitentes completamente desconocidas podría ser inferior al observado en la evaluación.

5. **Entrenamiento de la etapa A.** El autoencoder alcanzó el máximo de 300 épocas sin activar una parada temprana. Durante las últimas diez épocas, la mejora fue del 2.6%. Una ejecución previa con 80 épocas produjo una brecha de seis puntos de PR-AUC frente al clasificador entrenado desde cero, en comparación con los nueve puntos observados con 300 épocas. Esta diferencia sugiere que un entrenamiento más prolongado del autoencoder podría perjudicar la transferencia hacia la tarea de clasificación. Sin embargo, al tratarse únicamente de dos puntos de medición, no permite establecer una relación concluyente.

Requisitos para Llevar el Sistema a un Corredor Real

La transición de este prototipo a un sistema operativo requeriría incorporar información y controles que no están presentes en los datos utilizados.

1. **Información del cliente.** El falso positivo analizado muestra el costo de no disponer de contexto sobre el remitente. Un sistema de producción debería incorporar información como el tipo de cliente (persona o empresa), su actividad declarada y su perfil transaccional esperado. Estos datos forman parte de los procesos de conocimiento del cliente y no fueron utilizados por el modelo.
2. **Gobierno del umbral y monitoreo de deriva.** El límite de revisión del 1% representa, en una institución real, una decisión relacionada con la capacidad disponible para investigar alertas. El umbral debe documentarse junto con sus efectos sobre la detección y la carga de trabajo. Además, los patrones de remesas

pueden cambiar por factores estacionales o por modificaciones en las estrategias utilizadas para evadir los controles. Por ello, el sistema debe incorporar monitoreo de **deriva**, es decir, mecanismos para detectar cambios sostenidos en las características de los datos respecto a aquellas observadas durante el entrenamiento.

3. **Trazabilidad y validación humana.** El Decreto 15-2026 establece la necesidad de contar con un manual de prevención documentado y realizar auditorías periódicas de efectividad. Para respaldar estos procesos, cada alerta debería conservar información como la versión del modelo utilizada, el umbral vigente, las entradas relevantes y la explicación de la decisión. La alerta del modelo debe servir como insumo para la investigación y no generar por sí sola un reporte a la autoridad.
4. **Revisión de la arquitectura seleccionada.** Para la implementación se exporta la configuración de dos etapas con tasa de aprendizaje reducida, porque permite conservar las dos señales y mantener el diseño planteado originalmente. Sin embargo, esta configuración presenta una pérdida de nueve puntos de PR-AUC frente al clasificador entrenado desde cero. Una alternativa sería utilizar la variante con tasa de aprendizaje uniforme, que conserva ambas etapas y recupera siete de esos nueve puntos, o utilizar el clasificador entrenado desde cero y mantener la etapa A únicamente como señal secundaria para apoyar el análisis de las alertas.

Referencias

- Altman, E., Blanuša, J., Luc, V. N., Egressy, B., Anghel, A., & Atasu, K. (22 de junio de 2023). *Realistic synthetic financial transactions for Anti-Money laundering models*. arXiv.org. <https://arxiv.org/abs/2306.16424>
- Cardoso, M., Saleiro, P., y Bizarro, P. (2022). *LaundroGraph: Self-Supervised Graph Representation Learning for Anti-Money Laundering*. Proceedings of the Third ACM International Conference on AI in Finance (ICAIF '22), pp. 130-138. <https://doi.org/10.1145/3533271.3561727>
- Pang, G., Shen, C., Cao, L., & Van Den Hengel, A. (2021). Deep learning for anomaly detection. *ACM Computing Surveys*, 54(2), 1–38. <https://doi.org/10.1145/3439950>
- Lin, T., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017, August 7). *Focal loss for dense object detection*. arXiv.org. <https://arxiv.org/abs/1708.02002>
- Loshchilov, I., & Hutter, F. (2017, November 14). *Decoupled weight decay regularization*. arXiv.org. <https://arxiv.org/abs/1711.05101>
- Higueros, D. (17 de junio de 2026). *Decreto 15-2026 del Congreso de la República de Guatemala, Ley Integral para la Prevención y Represión del Lavado de Dinero u Otros Activos y el Financiamiento del Terrorismo*. Ministerio De Finanzas Públicas. <https://www.minfin.gob.gt/decreto-16-2026-del-congreso-de-la-republica-de-guatemala-ley-integral-para-la-prevencion-y-represion-del-lavado-de-dinero-u-otros-activos-y-el-financiamiento-del-terrorismo/>

Gamarro, U. (9 de enero de 2025). Remesas familiares en Guatemala cerraron el 2024 con nuevo récord histórico superando los US\$21 mil millones. *Prensa Libre*.
<https://www.prensalibre.com/economia/remesas-familiares-en-guatemala-cerraron-el-2024-con-nuevo-record-historico-superando-los-us21-mil-millones/>

Uso de Herramientas de IA Generativa

Se utilizó Claude como asistente de programación durante todo el proyecto. Su función se limitó principalmente a implementar las decisiones tomadas por el grupo: generó el código de los módulos, cuadernos y componentes de la aplicación a partir de instrucciones específicas, además de realizar modificaciones y correcciones solicitadas durante el desarrollo. La ejecución se realizó en *Google Colab* con GPU y los resultados reportados corresponden a dicha ejecución.

Las decisiones de diseño, metodología y evaluación fueron tomadas por el grupo. Entre ellas estuvieron seleccionar *Kaggle* como fuente citable en lugar del espejo público sugerido (y encontrado) por el asistente, determinar la cantidad de cuadernos, seleccionar el destino del despliegue, definir la representación de las secuencias, establecer los criterios de entrenamiento y solicitar el experimento de escasez de etiquetas.

También se revisaron y corrigieron propuestas del asistente cuando no coincidían con el análisis del grupo. Por ejemplo, al detectar que la etapa A no había convergido adecuadamente, se decidió cuadruplicar su presupuesto de entrenamiento. Posteriormente, se solicitó separar el efecto de la inicialización del efecto del *learning*

rate, lo que permitió identificar que la mayor pérdida de desempeño provenía de la tasa de aprendizaje reducida. Esta decisión fue fundamental para establecer el diagnóstico central del reporte.

En consecuencia, Claude se utilizó como herramienta de implementación y apoyo técnico, mientras que el grupo conservó la responsabilidad sobre las decisiones que determinan el diseño, los experimentos y las conclusiones del proyecto.